物理信息神经网络（PINNs）实验报告

姓名 ： 张春啸
学号 ： 2021013475
日期 ： 2026/3/30

目录

1 FDM 数值方法 **2**

2 标准 PINNs 方法 **2**

3 改进方法 **3**

3.1 自适应激活函数（ada） 3

3.2 残差自适应重采样（rar） 3

4 实验结果与分析 **4**

4.1 可视化结果对比 4

4.1.1 $\nu = 0.01/\pi$ 4

4.1.2 $\nu = 0.001/\pi$ 5

4.2 定量指标分析 6

4.3 结果讨论 6

1 FDM 数值方法

为获得 Burgers 方程的高可信参考解，采用有限差分法（FDM）进行数值求解。具体做法是：在空间区间 $x \in [-1, 1]$ 与时间区间 $t \in [0, 1]$ 上构造均匀网格；对扩散项 u_{xx} 使用二阶中心差分离散，对对流项 uu_x 使用随速度符号切换的一阶迎风差分离散；时间推进采用显式欧拉格式，并在每个时间步强制施加边界条件 $u(-1, t) = u(1, t) = 0$。初值取 $u(x, 0) = -\sin(\pi x)$。最终得到的时空离散解作为 PINNs 训练后评估时的参考真值，用于计算相对 L_2 误差与 MSE 等指标。

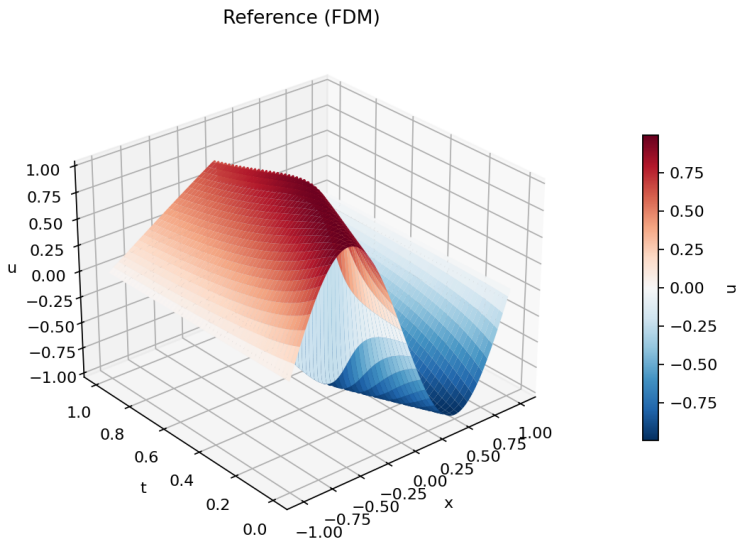

图 1: $\nu = 0.01/\pi$ 下的 FDM 参考场

2 标准 PINNs 方法

标准 PINNs 的核心思想是：用神经网络 $u_\theta(x, t)$ 近似 PDE 的解函数，并通过自动微分将物理方程残差直接加入训练目标。本文采用多层全连接网络（MLP）作为近似器，输入为 (x, t)，输出为标量场值 u。

针对 Burgers 方程

$$u_t + uu_x = \nu u_{xx},$$

构造三部分损失：

$$\mathcal{L} = \mathcal{L}_{ic} + \mathcal{L}_{bc} + \mathcal{L}_{pde},$$

其中

$$\mathcal{L}_{ic} = \frac{1}{N_{ic}} \sum_{i=1}^{N_{ic}} \left| u_\theta(x_i, 0) - u_0(x_i) \right|^2,$$

$$\mathcal{L}_{bc} = \frac{1}{N_{bc}} \sum_{j=1}^{N_{bc}} \left(|u_\theta(-1, t_j) - 0|^2 + |u_\theta(1, t_j) - 0|^2 \right),$$

$$\mathcal{L}_{pde} = \frac{1}{N_f} \sum_{k=1}^{N_f} |u_t + u u_x - \nu u_{xx}|^2_{(x_k, t_k)}.$$

这里 u_t, u_x, u_{xx} 均由自动微分计算。训练时使用 Adam 优化器最小化总损失，并在采样点上不断迭代更新网络参数。最终在规则网格上评估预测解，与 FDM 参考解对比，计算相对 L_2 误差和 MSE 作为性能指标。

控制方程：

$$u_t + u u_x = \nu u_{xx}, \quad x \in [-1, 1],\ t \in [0, 1].$$

3 改进方法

针对标准 PINNs 在小粘性系数下容易出现的收敛困难与误差偏大问题，本文采用了两种改进策略：自适应激活函数与残差自适应重采样（RAR）。

3.1 自适应激活函数（ada）

标准 MLP 常用固定激活 $\tanh(z)$。在本方法中，将其改为

$$\tanh(\alpha z),$$

其中 α 为可训练参数，并与网络权重共同优化。该设计能够动态调节网络非线性强度，使模型在训练过程中更灵活地适配不同尺度的解结构，尤其有助于提升对陡峭梯度区域的表达能力。

3.2 残差自适应重采样（rar）

标准 PINNs 常采用均匀随机采样 PDE 配点，可能导致高残差区域关注不足。RAR 的思路是周期性执行以下步骤：

1. 在候选点池中随机采样；
2. 计算各点 PDE 残差幅值；
3. 选取残差最大的若干点（hard points）；
4. 用这些点替换部分训练配点，强化后续训练。

通过“哪里误差大就重点学哪里”，RAR 可以在一定程度上缓解采样与难点区域错配问题，提升训练稳定性。

本实验将以上两种方法分别与基线方法对比，评估它们在不同粘性系数下对相对 L_2 误差和 MSE 的影响，并分析其有效性与局限性。

4 实验结果与分析

4.1 可视化结果对比

为直观比较模型在不同粘性系数下的表现，本文先给出两组参数下的解场对比图。每组包含 4 幅图：FDM 参考解、base、ada、rar。

4.1.1 $\nu = 0.01/\pi$

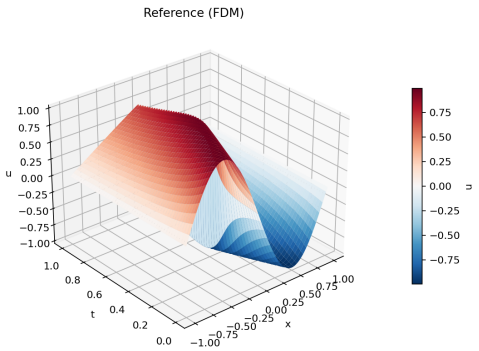

(a) FDM

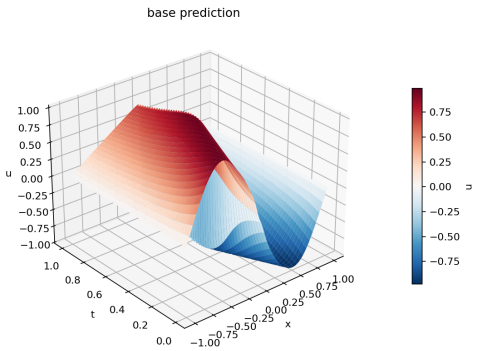

(b) base

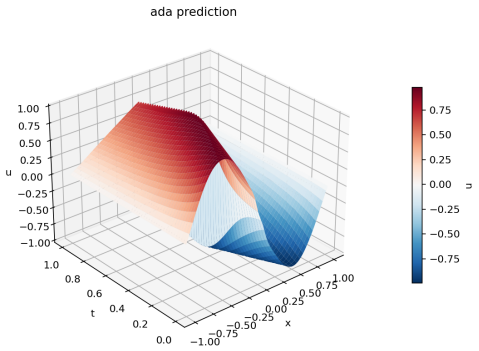

(c) ada

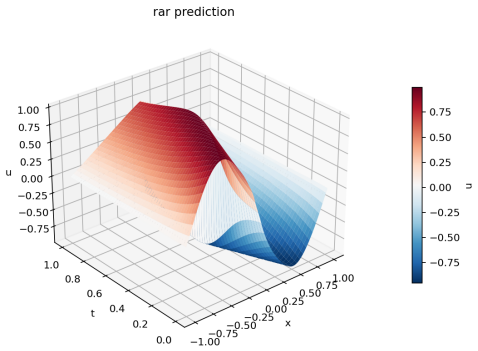

(d) rar

图 2: $\nu = 0.01/\pi$ 下三种 PINNs 与 FDM 对比

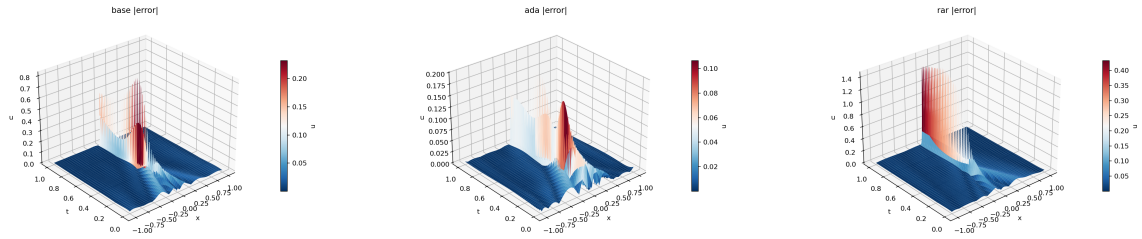

(a) base (b) ada (c) rar

图 3: $\nu = 0.01/\pi$ 下三种方法的误差场对比

4.1.2 $\nu = 0.001/\pi$

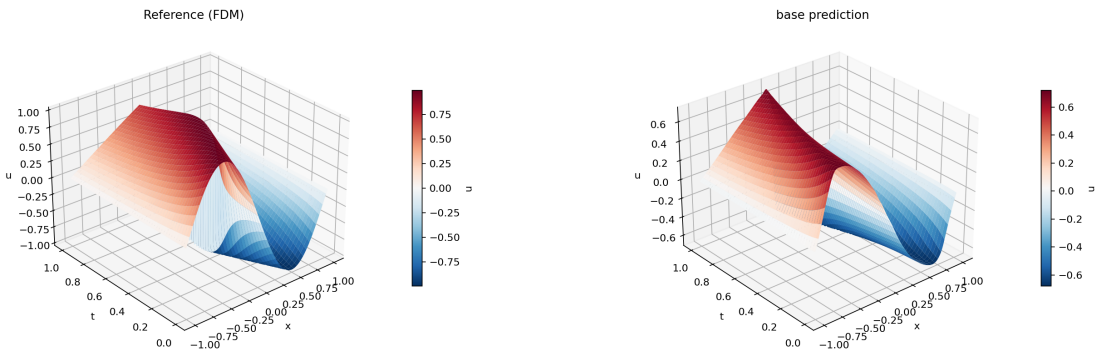

(a) FDM (b) base

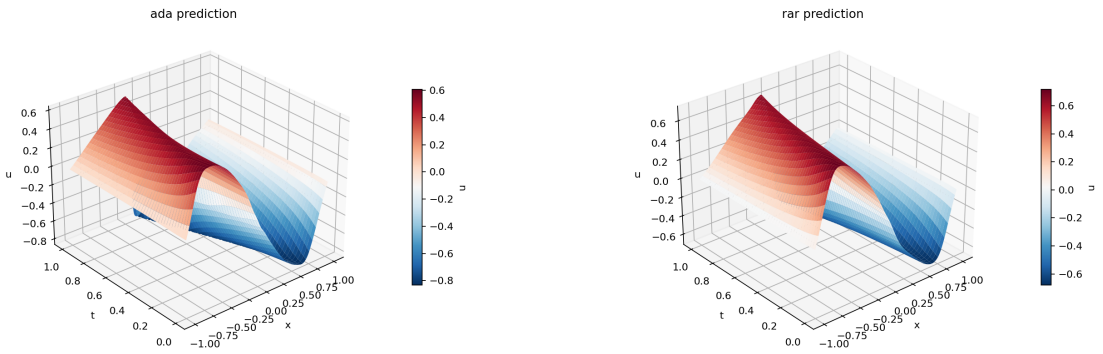

(c) ada (d) rar

图 4: $\nu = 0.001/\pi$ 下三种 PINNs 与 FDM 对比

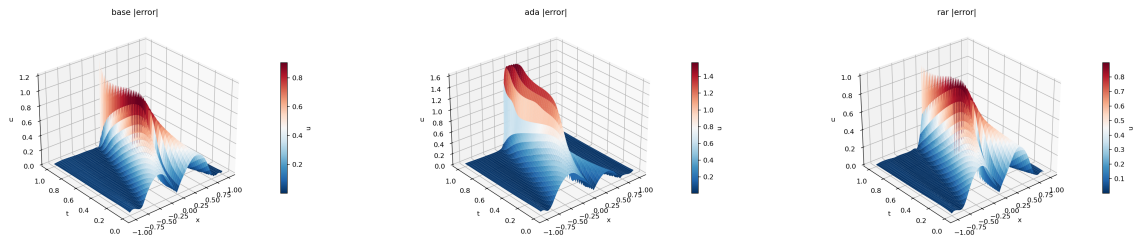

(a) base (b) ada (c) rar

图 5: $\nu = 0.001/\pi$ 下三种方法的误差场对比

4.2 定量指标分析

对应误差指标如下（rel_l2 越小越好）：

表 1: 两组粘性系数下三种方法误差对比

ν_{input}	方法	rel_l2	mse
0.01	base	6.94496e-2	1.79318e-3
0.01	ada	**2.75934e-2**	**2.83071e-4**
0.01	rar	1.63941e-1	9.99209e-3
0.001	base	**4.47943e-1**	**7.62785e-2**
0.001	ada	5.82598e-1	1.29031e-1
0.001	rar	4.48329e-1	7.64101e-2

4.3 结果讨论

在 $\nu = 0.01/\pi$ 条件下，ada 的结果最接近 FDM，误差明显低于 base 与 rar，说明自适应激活在该难度下能够提升拟合能力。当粘性系数减小到 $\nu = 0.001/\pi$ 时，三种方法误差均显著上升，表现出强对流场景下 PINNs 的训练退化现象；其中 base 与 rar 接近，ada 退化更明显。总体来看，改进方法并非在所有参数区间都稳定优于基线，方法效果与问题刚性程度和训练超参数存在显著耦合，需要针对小粘性场景进一步调参或引入更强的训练策略。