题目 A：PPI Link Prediction（蛋白互作链路预测，图链接预测）

PPI 预测是计算生物学与药物研发中的基础问题：实验验证互作网络耗时耗力，因此用计算模型预测“哪些蛋白会互作”一直是热点。近几年趋势非常明确：

- **sequence-only** 的深度模型（不依赖结构）在跨物种、低监督、可解释性方面持续进展，如 **D-SCRIPT**（Cell Systems, 2021）强调“从序列做结构启发式的互作预测”。
- 更强的 **蛋白语言模型（PLM）+ 互作建模** 也在近两年进入正刊体系，例如 **PLM-interact**（Nature Communications, 2025）专门系统 benchmark 了多种 PPI 预测方法并提出基于 PLM 的互作预测框架。
- 从“图机器学习”的角度，PPI 天然就是图（蛋白为点、互作为边），GNN/Graph AutoEncoder/GAT 等方法被大量用于 **PPI 链路预测**，并有专门综述/比较研究总结该方向。 https://arxiv.org/abs/2404.10450

既是生物重要任务，又是图学习核心任务（negative sampling、inductive vs transductive、冷启动蛋白、跨物种泛化等）。

问题定义（输入 / 输出）

设置 A（标准 Graph Link Prediction：Transductive）

- **输入**
  1. 一个训练 PPI 图 $G = (V, E)$，节点是 protein_id，边是已知互作
  2. 节点特征 x：蛋白序列 embedding（例如 ESM/ProtT5）或简单 k-mer/one-hot pooling
- **输出**
  - 对候选边 (u, v) 输出一个分数 $s(u, v) \in [0,1]$，表示“互作概率”
  - 二分类标签：$\hat{y} = \mathbb{1}[s(u, v) \geq t]$

设置 B（Inductive / Cold-start link prediction）

- **输入**
  - 训练图仍是 PPI 网络
  - 但测试时包含**训练图中从未出现的新蛋白节点**（只给序列）
- **输出**
  - 新节点与已有节点之间的互作概率

作业要求：

学生需提交实验报告及代码，主要关于以下几个指标：

- **交叉熵损失（BCE）**：模型预测链接预测的分类误差。

- **链接预测准确度（AUC）：**衡量模型对于链接预测问题的性能评价。

参考资源：

代码框架：https://github.com/liudan111/PLM-interact

数据集：human PPI dataset ：
https://figshare.com/articles/dataset/PPI_prediction_from_sequence_gold_standard_dataset/21591618

参考论文：

Lin Z, Akin H, Rao R, et al. Evolutionary-scale prediction of atomic-level protein structure with a language model[J]. Science, 2023, 379(6637): 1123-1130. （ESM 蛋白质语言模型）
Kipf T N, Welling M. Semi-supervised classification with graph convolutional networks[J]. arXiv preprint arXiv:1609.02907, 2016.（图卷积神经网络）
Veličković P, Cucurull G, Casanova A, et al. Graph Attention Networks[C]//International Conference on Learning Representations. 2018.（图注意力网络）

题目 B：Single-cell Perturbation Prediction（单细胞扰动响应预测）

单细胞扰动（CRISPR/药物/组合扰动）能揭示因果机制，但实验成本高、组合空间爆炸。当前前沿目标是实现 in silico perturbation：给定细胞状态与扰动条件，预测扰动后的转录响应，从而用于靶点筛选、机制推断与组合疗法设计。

该方向的代表性正刊工作之一是：

- **GEARS（Nature Biotechnology, 2024/online 2023）：**将深度学习与基因关系图（knowledge graph）结合，预测单基因与多基因组合扰动的转录后果，并强调对“未见过组合”的泛化能力。

同时，社区也在推动统一数据与 benchmarking：

- scPerturb（Nature Methods, 2024）：汇总并统一处理 44 个公开单细胞扰动数据集（多组学 readouts），显著降低方法开发与对比评测门槛，是做课程作业/benchmark 的非常强支撑。

另外，2026 年仍持续出现新的图方法推进该任务：PrePR-CT（Nature Machine Intelligence, 2026）将细胞类型特异的共表达网络作为 inductive bias，用图模型预测化学扰动响应。

问题定义（输入 / 输出）

输入

- 基线单细胞表达向量$x \in \mathbb{R}^{\mathbb{G}}$（G 个基因）
- 扰动条件 $P = \{g_1, \dots, g_k\}$（单基因或多基因组合；可加扰动类型 KO/OE/drug）
- 可选 covariates：cell type、batch、dose、time

输出

- 扰动后表达 $\hat{y} \in \mathbb{R}^{\mathbb{G}}$，或更常见地输出 $\Delta\hat{y} = \hat{y} - x$
- 可选：只预测 top-DE genes 或 pathway scores（降低计算量）

作业要求：

学生需提交实验报告及代码，主要关于以下几个指标：

- **均方误差（MSE）：**模型预测扰动后的基因表达和真实基因表达之间的区别。

参考资源：

代码框架：https://github.com/snap-stanford/GEARS

数据集：norman dataset ：https://github.com/snap-stanford/GEARS

Core API Interface

Using the API, you can (1) reproduce the results in our paper and (2) train GEARS on your perturbation dataset using a few lines of code.

```
from gears import PertData, GEARS

# get data
pert_data = PertData('./data')
# load dataset in paper: norman, adamson, dixit.
pert_data.load(data_name = 'norman')
# specify data split
pert_data.prepare_split(split = 'simulation', seed = 1)
# get dataloader with batch size
pert_data.get_dataloader(batch_size = 32, test_batch_size = 128)

# set up and train a model
gears_model = GEARS(pert_data, device = 'cuda:8')
gears_model.model_initialize(hidden_size = 64)
gears_model.train(epochs = 20)

# save/load model
gears_model.save_model('gears')
gears_model.load_pretrained('gears')

# predict
gears_model.predict([['CBL', 'CNN1'], ['FEV']])
gears_model.GI_predict(['CBL', 'CNN1'], GI_genes_file=None)
```

参考论文：

Roohani Y, Huang K, Leskovec J. Predicting transcriptional outcomes of novel multigene perturbations with GEARS[J]. Nature Biotechnology, 2024, 42(6): 927-935. （GEARS）

Kipf T N, Welling M. Semi-supervised classification with graph convolutional networks[J]. arXiv

preprint arXiv:1609.02907, 2016.（图卷积神经网络）
Veličković P, Cucurull G, Casanova A, et al. Graph Attention Networks[C]//International Conference on Learning Representations. 2018.（图注意力网络）